

Kockázatmodellezés és -előrejelzés

Salamon András, Szilágyi Gergő

Hitelek és kockázatok makro és mikro szinten

2023. tavaszi félév

Tartalomjegyzék

1. Historikus VaR	3
2. Szimulált VaR	3
3. EWMA	3
4. Machine Learning	4

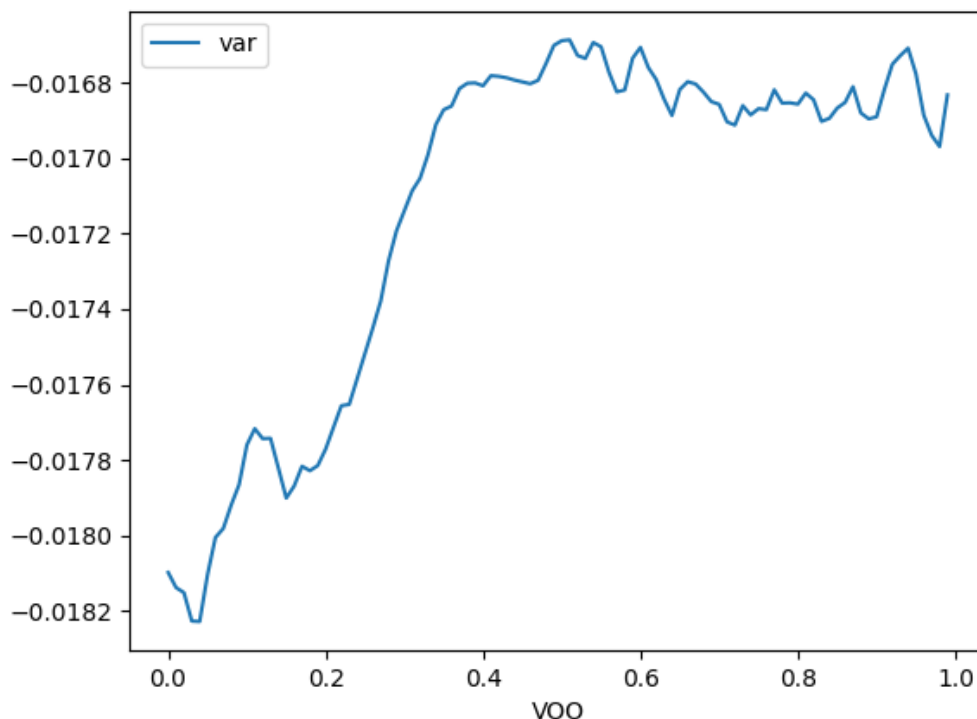
Ábrák jegyzéke

1. EWMA a MOO idősoros adatokon a két decay faktor mellett 3

1. Historikus VaR

A Value at Risk (VaR) egy mutató, amivel egy eszköz, vagy egy portfólió lehetséges veszteségét lehet számszerűsíteni. Azt mutatja meg, hogy adott konfidenciaintervallum mellett legrosszabb esetben mennyit veszítünk a befektetésünkkel. A VaR számításának egyik módja a historikus VaR, amikor múltbeli adatokból indulunk ki. A feladatunk ennek kiszámítása volt egy kételemű portfólióra. Két ETF-et, a MOO-t és a VOO-t választottuk ehhez.

A két eszköznek összesen 100 féle súlyozását néztük meg, ami az egész $[0, 1]$ intervallumot lefedte. Így megkaptuk azt az optimális súlyozást, ami a legjobb historikus VaR értéket adja.




1. ábra. VaR értéke a VOO súlyának függvényében, 95%-os konfidencia szint mellett

Ahogy az ábrán az látható, kb. 0.2%-os VaR eltérést tudunk elérni az eszközök optimális súlyozásával. A legmagasabb VaR érték -1,67%, ez azt jelenti, hogy a hozamok 95%-a ennél magasabb volt. Ehhez majdnem fele-fele arányban kell venni a két eszközt: a VOO súlya 0.51, a MOO-é 0.49.

2. Szimulált VaR

3. EWMA

Az EWMA (Exponentially Weighted Moving Average) segítségével szimulálható a pénzpiacokon megfigyelhető volatilitásklasztereződés. Eszerint azokat a napokat volatilisabb napok követik, amelyeken jobban ingadozik az árfolyam, valamint ez fordítva is igaz, a nyugodtabb napokat nyugodtabb napok követik. Az EWMA-ban az előző időszak loghozamok négyzetét exponenciálisan csökkenő súlyokkal súlyozzuk. Az, hogy mennyire gyors az exponenciális csökkenés, a decay faktor értéke határozza meg. A súlyokat egyre normálva nagyobb decay faktor mellett kisebb súlyokat kapunk, azonban a súlyok lassabban csökkennek.



2. ábra. EWMA a MOO idősoros adatokon a két decay faktor mellett

Ahogy az ábrán látható, nagyobb decay faktor mellett nagyobb az előrejelzett volatilitás, azonban ebben az esetben a volatilitások jobban klasztereződnek, mivel nem olyan nagyok a kilengések, mint kisebb decay faktor mellett.

4. Machine Learning

Végezetül készítettünk egy lineáris regressziós modellt is a jövőbeli variancia múltbeli adatokból történő előrejelzésére. A célváltozó az adott napi loghozam négyzete, a magyarázó változó pedig az előző 10 napi loghozamok négyzete, az EWMA módszeréhez hasonlóan.

Az optimális fokszám megtalálásához hiperparaméter-keresést végeztünk, ennek az eredménye az lett, hogy a legalacsonyabb MSE az elsőfokú modell mellett volt. A cross-validation ezt az eredményt megerősítette. A végső modell koefficiensei a következők:

$$(0.1335, 0.0755, 0.0190, 0.0989, -0.0552; 0.0695, 0.0981, 0.0971, 0.0656, -0.0007).$$

Látható, hogy a legnagyobb koefficiens a legelső változóhoz, azaz az 1 nappal korábbi loghozamhoz tartozik. Ez megfelel a várakozásainknak. A korábbi napi adatokhoz tartozó koefficiensek azonban nem szabályosan csökkennek, így kétséges, hogy mennyire használható a modellünk. Ha nem csak bő 2 év adatait vizsgáljuk, és/vagy több napra visszamenően vesszük a magyarázó változókat, talán jobb modellt kaphatunk.